SpeechArena インフラ運用報告

LLM-jp Moshi 音声対話モデルの A/B 評価基盤

2026-04-14

今日お伝えしたいこと

1. **現状の構成**: 研究室GPU ベース、動作確認完了
2. **課題**: 研究室GPU ではワーカーが**1人ずつ**しか評価できない
3. **選択肢**: AWS への移行を検討したいが、**技術面とコスト面でトレードオフ**がある
4. **ご相談**: クラウドソーシング規模に合わせてどう段階的に進めるか

現状の構成

```
ワーカー (ブラウザ)
  ↓ HTTPS
Vercel (Next.js, 無料)
  ├─ フロント: https://web-fawn-five-91.vercel.app
  └─ DB: Supabase PostgreSQL (無料)
  ↓ Cloudflare Tunnel (HTTPS)
研究室サーバー (RTX 3090 × 2)
  ├─ moshi-server A (ポート 8998) ← Model A
  └─ moshi-server B (ポート 8999) ← Model B
```

- 6種類の LLM-jp Moshi モデルのうち 2つを常時起動
- 評価セッションで **A×2会話** → **B×2会話** → **投票** の流れ（所要 約10分）
- FD-DMOS 4指標 + 成功/失敗 + パケットロス で定量評価

課題: 同時 1 ワーカーしか捌けない

- RTX 3090 は 24GB VRAM → **1枚で1モデルが上限**
- 2枚 = 2モデル同時起動が物理上の上限
- **ワーカーが会話中は GPU 占有**、2人目は待機

クラウドソーシングの現実的影響

ワーカー数	所要時間（1セッション 10分）
10人	100分（1.7時間）
50人	8.3時間
100人	16.7時間

→ 規模を上げるには並列化が必須

選択肢A: AWS に全面移行

技術面

- **オートスケーリング**: ワーカー数に応じて GPU インスタンスを自動追加
- **Warm Pool**（常時起動プール）: 2人目以降の待ち時間を最小化（3-5分 → 即時）
- 6モデルから**ランダム2モデル**を動的に割当可能

ボトルネック

- Moshi モデルのロードに **コールドスタート 15-20分**
- ウォームスタートでも 3-5分
- → **Warm Pool が UX 改善の鍵**

AWS GPU インスタンスの選定結果

2モデル同時起動に必要な VRAM: **34GB**

インスタンス	VRAM	同時モデル数	備考
g5.xlarge (A10G 24GB)	24GB	1	1モデルのみ
g5.2xlarge (A10G 24GB)	24GB	1	1モデルのみ
g6e.xlarge (L40S 48GB)	**46GB**	**2**	✅ 採用

- 東京リージョン: **Spot GPU の vCPU quota = 0**（利用不可）
- → us-east-1 で On-demand 運用

コスト: AWS で GPU を常時起動した場合

g6e.xlarge (us-east-1, on-demand) = **$1.86/h**

運用パターン	GPU 時間/月	月額
評価時のみ（1日2h × 週5）	44h	**~$96**
勤務時間帯のみ（8h × 週5）	176h	**~$336**
常時起動（Warm Pool 1台）	720h	**~$1,340**
常時起動 × 2台（並列対応）	1,440h	**~$2,680**

- EBS 200GB = $16/月、データ転送・S3 数ドル

技術課題とコストのトレードオフ

要件	技術手段	月額コスト目安
1人ずつ捌ければ良い	研究室GPU	**$0**（電気代のみ）
学外公開、数人並列	AWS オンデマンド（使う時だけ起動）	~$100-300
UX 重視・待ち時間ゼロ	**常時起動（Running 保持）1台**	~$1,340
大規模クラウドソーシング	ASG + 常時起動複数台	~$2,000+

用語整理

- **常時起動（Running 保持）**: 24/7 起動。即応可、$1.86/h 課金
- **待機プール（Stopped 保持）**: 停止状態で予備確保。EBS のみ課金、起動 3-5 分
- **コールドスタート**: 新規起動。15-20 分

→ **「何人同時を許容するか」「どの程度の待ち時間を許容するか」で選択**

実装状況

項目	状態
Terraform コード（S3/ECR/DynamoDB/IAM/EC2/Lambda/API Gateway）	✅ 完了
Lambda オーケストレーター（ランダム割当ロジック、548行）	✅ コード完了
プリウォーミング起動スクリプト（`start-gpu.sh`）	✅ 動作確認済み
実 AWS 上の Lambda デプロイ	⚠️ Terraform drift あり、要再デプロイ
認証（不正データ対策）	❌ Issue #3
Bradley-Terry ランキング（全ペア網羅不要）	❌ Issue #8
音声録音 → S3	❌ Issue #10

提案: 段階的移行ロードマップ

Phase 1 — 今すぐ（学内クラウドソーシング）

- **研究室GPU のまま** 1ペアずつ評価データ収集
- Bradley-Terry 実装で全ペア網羅不要に
- コスト: **$0**

Phase 2 — 学外公開準備（2-3週）

- AWS に移行、認証追加、動的モデル割当復活
- **使う時だけ起動**（自動停止スケジューラ）
- コスト: ~**$100-300/月**

Phase 3 — 本格運用（必要に応じて）

- 常時起動（Running 保持）+ Auto Scaling で待ち時間ゼロ
- コスト: ~**$1,340-2,680/月**

運用案: 募集期間に合わせた弾力運用

基本方針

- **通常期間**（開発・検証）: 日中 8時間のみ起動 or コールドスタート（使う時だけ）
- **クラウドソーシング募集期間**: **常時起動（Running 保持）GPU を複数台に増やし、並列4-5人**捌けるようにする

ポイント

- 常時起動 1台 = 同時1-2人 → **募集期間だけ ASG でスケールアップ**
- 理想: 並列 4-5 人対応（g6e.xlarge を 3-4 台 Running 保持）
- 募集終了後は 1台 or 自動停止に戻す

運用案: コスト見積もり

運用モード	GPU 台数	想定月額	捌ける並列数
通常期（コールドスタート）	0（必要時起動）	~$50	1（待ち3-5分）
通常期（日中8h × 週5）	1	~$336	1-2
募集期間（常時起動 複数台）	3-4	**~$4,000-5,400**	**4-5人並列**

年間イメージ（通常期 10ヶ月 + 募集期 2ヶ月連続の場合）

- 通常期: $336 × 10 = ~$3,360
- 募集期: $5,000 × 2 = ~$10,000
- **年間合計: 約 $13,000-14,000**

→ **募集期間をどの程度の頻度・期間で設定するかがコストの肝**

運用案: 短期集中募集（より現実的）

g6e.xlarge × 3-4台 を **募集期間だけ常時起動**した場合の実コスト：

募集期間	3台	4台
2日 (48h)	**~$268**	**~$357**
1週間 (168h)	~$938	~$1,251
2週間 (336h)	~$1,876	~$2,501
1ヶ月 (720h)	~$4,019	~$5,359

年間イメージ（2日集中募集 × 年4回 + 通常期 日中8h×週5 で1台）

- 通常期: $336 × 12 = ~$4,030
- 募集期: $300 × 4 = ~$1,200
- **年間合計: 約 $5,200**

→ 短期集中型ならコストを大幅に抑えられる

ご相談事項

1. **クラウドソーシングの目標規模**は?
    - 学内数十人 / 学外数百人 / 大規模 1000人+
2. **予算感**は?
    - Phase 2（~$300/月）で収めるべきか
    - Phase 3（~$1,340+/月）まで許容できるか
3. **公開時期**は?
    - 論文投稿との兼ね合いで Phase 2 → 3 の切替タイミング

補足: 既存 GitHub Issue (1/2)

必須（公開前）

- #3 認証機能
- #4 Moshi エンドポイント管理
- #13 動的モデル割当（Lambda 復活）
- #14 Cloudflare Named Tunnel（固定ドメイン）

データ品質

- #8 Bradley-Terry ランキング
- #10 音声録音 → S3
- #9 自動会話成功判定

補足: 既存 GitHub Issue (2/2)

運用・拡張

- #5 同時接続数制御
- #11 AWS 移行全体
- #15 GPU 自動停止
- #16 コスト監視