評価指標の再設計

具体項目の列挙から抽象軸への導出プロセス

阿部 雄斗 — SpeechArena

2026/04/21

前回（4/14）の指摘

> 4軸が抽象的すぎて、なぜその軸なのかを説明できない。

- 現行 4軸: **音声自然性 / 聴感自然性 / 意味理解性 / 対話有用性**
- 3軸は「低品質前提」、対話有用性だけ粒度が一段高い
- 「音は悪い・会話できていない、でも有用」という矛盾が起きうる

今日の目的

- 具体的な評価観点をまずフラットに並べる
- そこから抽象軸へ再構成する案を提示する
- 論文に書ける「導出プロセス」の輪郭を固める

プロセス全体像

Step 1 **具体項目を列挙**
抽象軸を意識せずフラットに並べる

Step 2 **既存プロトコルを参照**
ITU 標準の発展段階と対話音声の現在地を確認

Step 3 **クラスタリング → 抽象軸**
類似項目をまとめて軸名を付ける

Step 4 **現行 4軸との対応づけ**
粒度もここで揃える

Step 5 **UI に落とす**
実装反映（次フェーズ）

本日は **Step 1〜4** の叩き台を議論します。

Step 1: とにかく書き出す（27 項目・順不同）

- ノイズは気になりましたか？
- 人と話している感じがしましたか？
- 発話を始めるタイミングは自然でしたか？
- 発話の意味は聞き取れましたか？
- 音量は安定していましたか？
- 相槌は自然でしたか？
- 感情表現は豊かでしたか？
- 前の話を覚えていましたか？
- 発音は明瞭でしたか？
- 会話の目的は達成できましたか？
- 終話のタイミングは自然でしたか？
- 根拠のない発言はありませんでしたか？
- 声質は自然でしたか？
- 沈黙の扱いは自然でしたか？
- 応答速度は人間らしかったですか？
- 話題は噛み合っていましたか？
- 抑揚・アクセントは自然でしたか？
- 割り込んだ時の反応は自然でしたか？
- キャラクターは一貫していましたか？
- 質問に的確な応答が返りましたか？
- 話す速さや間は自然でしたか？
- 音が途切れませんでしたか？
- また話したいと思いましたか？
- 会話はスムーズに進みましたか？
- 応答に遅延はありませんでしたか？
- 情報として役に立ちましたか？
- 音に歪みはありませんでしたか？

Step 2: プロトコル標準化の発展段階

段階 1	段階 2	段階 3	段階 4
個別研究	**複数論文で再現**	**ベストプラクティス化**	**ITU 等で標準化**
単発論文で提案	他者追試・収束	推奨手法に収束	公式プロトコル

合成音声は段階 4 まで到達している

- **ITU-T P.800** — ラボ環境での主観音声品質評価
- **ITU-T P.808** — クラウドソーシング版
- **ITU-R BS.1534** — MUSHRA（参照付き多試料比較）
- 各研究室の MOS 的手法が、再現→ベストプラクティス化を経て ITU 標準へ

対話音声は段階 1〜2 付近

- **対話版 P.800 / P.808 は未成立**
- SSA（テキスト対話）、FD-Bench 等のベンチマーク提案が散発的にある段階
- → 本研究は **段階 1 の個別提案** として FD-DMOS を位置づける

Step 2 (続): 対話音声ならではの違い

なぜ対話音声は標準化が遅れているのか:

静的な 1 発話ではなく、時間軸を持つ

ターンの切り替え、沈黙、相槌、割り込みなど **動的な挙動** を評価対象に含む必要がある。

評価者が「聴衆」ではなく「当事者」

P.800 系は録音済み音声を聴いて採点するが、対話は **評価者自身が話し手** になる。

→ 試料ごとに体験が変わり、参照音声の置き方も単純ではない。

リアルタイム性

P.800 の遅延測定は通信品質としてあるが、**応答生成の遅延** は別概念。

Step 3: クラスタリング → 抽象軸

抽象軸	主な具体項目	粒度
Ⅰ. 音響品質	ノイズ・発音・プロソディ・音量・話速	低
Ⅱ. 対話進行のタイミング	発話開始/終話・相槌・沈黙・割り込み	低〜中
Ⅲ. 人間らしさ・聴感	人と話している感覚・感情表現・応答速度・キャラ一貫性	中
Ⅳ. 意味・応答の妥当性	意味聞き取り・的確な応答・文脈保持・ハルシネーション	中
Ⅴ. 対話としての有用性	目的達成・また話したい・情報有益・スムーズ進行	高

音切れ・遅延は独立した二値項目（通信品質）として継続。

Step 4: 現行 4軸との対応

現行	新案	変更点
音声自然性	Ⅰ. 音響品質	音響項目を具体化
聴感自然性	Ⅲ. 人間らしさ・聴感	人間らしさに寄せ直し
意味理解性	Ⅳ. 意味・応答の妥当性	文脈保持・ハルシネーションまで網羅
対話有用性	Ⅴ. 対話としての有用性	高粒度のまま独立扱い
—	Ⅱ. 対話進行のタイミング	**新設**

現行軸を否定せず、**分解と補強** で再構成する方針。
Ⅱ を新設することで Full-Duplex モデルの特徴を捉える。

粒度問題への対応: 二段構成

Layer 1 — コンポーネント評価

低〜中粒度で揃える

Ⅰ. 音響品質 | Ⅱ. 対話進行のタイミング | Ⅲ. 人間らしさ・聴感 | Ⅳ. 意味・応答の妥当性

Layer 2 — 総合評価

高粒度・独立

Ⅴ. 対話としての有用性

- Layer 1 の 4軸は **同じ粒度** で揃える
- Layer 2 は独立した軸として分析時も別扱い
- これにより「音が悪くても有用」のような矛盾パターンを許容したまま、相関を論じられる

Step 5 先取り: UI に載せる質問（案）

Q1 音響品質はどう感じましたか？
ノイズ・発音・プロソディ
1 2 3 4 5

Q2 対話のタイミングはどう感じましたか？
相槌・ターン交代・沈黙
1 2 3 4 5

Q3 人と話している感じがしましたか？
感情表現・応答速度・キャラの一貫性
1 2 3 4 5

Q4 応答内容は妥当でしたか？
意味・文脈・ハルシネーション
1 2 3 4 5

— Layer 2 —

Q5 もう一度このモデルと話したいと思いましたか？
総合評価
1 2 3 4 5

— 付帯質問 —

Q6 会話は成功しましたか？
成功 失敗

Q7 音切れはありましたか？
あり なし

論文での記述プラン（SLT 4 ページ構成）

1. **背景** — ITU-T P.800/P.808 は対話音声未カバー、標準化の段階論
2. **評価軸の導出** — 27 項目列挙 → 親和図法 → 5軸 + 二段構成（全工程を 1 章に集約）
3. **評価プラットフォーム実装** — UI / Bradley-Terry / クラウドソーシング設計
4. **100 名パイロット評価** — 軸間相関・モデル間順位・被験者一致度
5. **考察** — 当事者評価の限界、リファレンス不在、次段階への布石

→ 導出プロセス（章 2）は **1 章に圧縮**、実装と運用結果（章 3–4）に紙幅を割いて差別化

残っているタスク

1. 質問事項の変更（UI 反映）

- 本日の議論を踏まえ、5軸 + Layer 2 の質問文を確定
- 付帯質問（成功/失敗・音切れ有無）のラベル調整

2. 100 名規模のクラウドソーシング評価

- SLT 投稿に向けた必要最小規模のデータ収集
- パイロット運用で軸間相関・モデル間順位を検証

運用規模とインフラの関係

規模	運営形態	インフラ要件
～100 名（SLT 向け）	**人数を絞って運営主導でクローズド運用**	現行構成で対応可
常時公開（本番運用）	誰でも参加できる開放型	**GPU 同時接続・負荷分散・認証含め再設計が必要**

→ 当面は 100 名クローズド運用に集中し、インフラ再設計は SLT 投稿後に着手

補足: リファレンス音声の扱い

案	内容	コメント
A	リファレンスなし（現行）	実装簡、当事者の主観基準
B	高品質リファレンス付き	MUSHRA 風、判断軸が揃う
C	極端例のみ提示（推奨）	ワーカー導入時に最低 / 最高のサンプルを一度だけ

C 案の実装コスト: 各軸 2 サンプル × 5軸 = **10 クリップ** の選定のみ。

関連資料

- `slides/2026-04-14_meeting-tasks.md` 前回議事のタスク化
- `slides/2026-04-14_infra-report.md` インフラ運用報告
- `apps/web/prisma/schema.prisma:95-100` 現行スキーマ
- `apps/web/src/components/wizard/steps/trial-step.tsx:175-198` 評価 UI