評価指標の再設計

具体項目の列挙から抽象軸への導出プロセス

阿部 雄斗 — SpeechArena

2026/04/21

前回（4/14）の指摘

> 4軸が抽象的すぎて、なぜその軸なのかを説明できない。

- 現行 4軸: **音声自然性 / 聴感自然性 / 意味理解性 / 対話有用性**
- 3軸は「低品質前提」、対話有用性だけ粒度が一段高い
- 「音は悪い・会話できていない、でも有用」という矛盾が起きうる

今日の目的

- 具体的な評価観点をまずフラットに並べる
- そこから抽象軸へ再構成する案を提示する
- 論文に書ける「導出プロセス」の輪郭を固める

プロセス全体像

```
Step 1   具体項目を列挙      抽象軸を意識しない
Step 2   クラスタリング      類似項目をまとめる
Step 3   抽象軸を命名        クラスタごとに名前を付ける
Step 4   現行4軸と対応づけ   粒度もここで揃える
Step 5   UI に落とす         実装反映
```

本日は **Step 1〜4** の叩き台を議論します。

Part 1: 具体項目を列挙する

Step 1 — 抽象軸を意識せずフラットに並べる

Step 1: 具体項目の列挙（音響レベル）

A. 発話の音響品質

- ノイズ・歪み・クリッピングがないか
- 音量の安定性（急な音量変化がないか）
- 発音の明瞭さ（子音欠落、母音の不鮮明さ）
- 声質の自然さ（合成音特有の金属音・ざらつき）
- プロソディ（ピッチ・アクセント）の自然さ
- 話速・ポーズ（間）の長さ

B. 通信品質

- 音切れ・途切れ（パケットロス）
- 遅延

Step 1: 具体項目の列挙（対話レベル）

C. ターンテイキング

- 発話開始タイミング
- 終話タイミング（被せてこないか）
- 相槌（バックチャネル）の自然さ
- 沈黙・ポーズの扱い
- 割り込み時の挙動

D. 聴感・人間らしさ

- 人と話している感覚
- 感情表現（抑揚、笑い、驚き）
- 応答速度の人間らしさ
- キャラクターの一貫性

Step 1: 具体項目の列挙（内容レベル）

E. 意味理解・応答内容

- 発話の意味が聞き取れる
- 質問に対して的確な応答が返る
- 文脈の保持（前の発話を覚えている）
- 話題が噛み合う、論理的に一貫している
- ハルシネーション（根拠なき情報）がない

F. 対話の有用性

- 目的を達成できた / もう一度話したい
- 会話がスムーズに進んだ / 情報として有益

→ A〜F の 6 カテゴリから計 **27 項目** を候補として抽出

Part 2: 抽象軸へ再構成する

Step 2–4 — クラスタリング・軸命名・現行軸との対応

Step 2: 参考にした既存プロトコル

プロトコル	対象	特徴
MOS	合成音声	単一発話・静的
MUSHRA	合成音声	参照あり・多試料比較
SSA	テキスト対話	sensibleness + specificity
Full-Duplex Challenge (IS 2024)	対話音声	naturalness / turn-taking / content

対話音声ならではの違い

合成音は静的な 1 発話、対話は **時間軸** を持ち、評価者が **当事者**。
ターンテイキングや沈黙の扱いなど、動的な観点が加わる。

Step 3: クラスタリング → 抽象軸

抽象軸	含まれる具体項目	粒度
Ⅰ. 音響品質	A1–A6（音・発音・プロソディ）	低
Ⅱ. 対話進行のタイミング	C1–C5（ターンテイキング）	低〜中
Ⅲ. 人間らしさ・聴感	A4, A7, D1–D4	中
Ⅳ. 意味・応答の妥当性	E1–E6	中
Ⅴ. 対話としての有用性	F1–F4	高

B1–B2（通信品質）は独立した二値項目として継続。

Step 4: 現行 4軸との対応

現行	新案	変更点
音声自然性	Ⅰ. 音響品質	A1–A6 に具体化
聴感自然性	Ⅲ. 人間らしさ・聴感	人間らしさに寄せ直し
意味理解性	Ⅳ. 意味・応答の妥当性	E1–E6 で網羅
対話有用性	Ⅴ. 対話としての有用性	高粒度のまま独立扱い
—	Ⅱ. 対話進行のタイミング	**新設**

現行軸を否定せず、**分解と補強** で再構成する方針。
Ⅱ を新設することで Full-Duplex モデルの特徴を捉える。

粒度問題への対応: 二段構成

```
Layer 1    コンポーネント評価（低〜中粒度で揃える）
           Ⅰ. 音響品質
           Ⅱ. 対話進行のタイミング
           Ⅲ. 人間らしさ・聴感
           Ⅳ. 意味・応答の妥当性

Layer 2    総合評価（高粒度・独立）
           Ⅴ. 対話としての有用性
```

- Layer 1 の 4軸は **同じ粒度** で揃える
- Layer 2 は独立した軸として分析時も別扱い
- これにより「音が悪くても有用」のような矛盾パターンを許容したまま、相関を論じられる

Part 3: UI・論文・議論

Step 5 先取りと、本日の論点整理

Step 5 先取り: UI に載せる質問（案）

```
Q1   音響品質 ..............   ノイズ / 発音 / プロソディ
Q2   タイミング ............   相槌 / ターン交代
Q3   人間らしさ ............   人と話している感覚
Q4   応答内容 ..............   意味 / 文脈 / 妥当性
──────────────────────────────────────────────────
Q5   総合（Layer 2）.......   また話したいか
──────────────────────────────────────────────────
Q6   会話は成功しましたか?     SUCCESS / FAILURE
Q7   音切れはありましたか?     YES / NO
```

各 Q に具体項目を tooltip で表示し、判断基準を揃える。

所要時間は現行と同等（評価入力 30 秒程度）。

論文での記述プラン

1. **背景** — MOS を Full-Duplex 対話にそのまま適用する困難
2. **Step 1 列挙** — 27 項目（Appendix に全リスト）
3. **Step 2–3 クラスタリング** — 親和図法 + 研究室内レビュー
4. **Step 4 軸命名** — 5軸 + 二段構成の提案
5. **Step 5 検証** — パイロット評価で軸間相関分析
6. **考察** — 当事者評価の限界、リファレンス不在の影響

→ 「なぜこの軸か」を **具体項目から逆算** して説明可能な形にする

今日議論したいこと

1. **27 項目** の過不足: 漏れや冗長はないか
2. **II. 対話進行のタイミング** を新軸として立てるべきか
3. **IV と V の境界** は明確か
4. **KJ 法 / 親和図法** のワークショップを開く価値はあるか

次回までのアクション（案）

タスク	担当	期限
27 項目の確定（本議論の反映）	阿部	4/28
パイロット評価で軸間相関分析	阿部	5 月前半
論文ドラフトの評価セクション執筆	阿部	5 月中旬

補足: リファレンス音声の扱い

案	内容	コメント
A	リファレンスなし（現行）	実装簡、当事者の主観基準
B	高品質リファレンス付き	MUSHRA 風、判断軸が揃う
C	極端例のみ提示（推奨）	ワーカー導入時に最低 / 最高のサンプルを一度だけ

C 案の実装コスト: 各軸 2 サンプル × 5軸 = **10 クリップ** の選定のみ。

関連資料

- `slides/2026-04-14_meeting-tasks.md` 前回議事のタスク化
- `slides/2026-04-14_infra-report.md` インフラ運用報告
- `apps/web/prisma/schema.prisma:95-100` 現行スキーマ
- `apps/web/src/components/wizard/steps/trial-step.tsx:175-198` 評価 UI