評価指標の再設計 v2

Q3 の再設計とブレイクダウン文

阿部 雄斗 — SpeechArena

2026/04/28

前回 (4/21) の指摘まとめ

Q3「人と話している感じがしましたか」が他を包含してしまう

- タイミングが悪くても「人と話している感じ」はしない
- 音質が悪くても「人と話している感じ」はしない
- → Q3 が Q1 (音声品質) / Q2 (タイミング) / Q4 (応答内容) をまるごと吸い込んでしまう

その他の指摘

- Q1〜Q4 で **文型がバラバラ**（「〜でしたか」「どう感じましたか」等）
- 各 Q は**補助文でブレイクダウン**すべき
- 「音響品質」は**ノイズ寄り**の印象 → 言い換えたい
- Q2 のスケールで「早/遅」どちらも悪い → **単調 1–5** で統一したい
- 発表で「キャラ」は若者言葉、「最適化」は評価語でない

本日のアップデート

- ✓ Q3 を「対話としての話し方」に再設計し、Q1/Q2/Q4 の包含を解消
- ✓ 各 Q にブレイクダウンした補助文を追加（4 項目ずつ）
- ✓ Q1〜Q4 の文型を「**〜はどうでしたか**」に統一
- ✓ 「音響品質」→「**音声の品質**」に改称
- ✓ Q2 のスケール注記を「1 = 悪い（早すぎ/遅すぎ両方）〜 5 = 良い」で明示
- ✓ 「キャラ」→「キャラクター」、「最適化」系の評価語を中立な語へ
- □ 100 名クラウドソーシングの実施設計（質問確定後）

Q3 の何が問題だったか（構造図）

評価観点	Q1 音声品質	Q2 タイミング	Q4 応答内容	旧 Q3 人らしさ
ノイズ・発音	●			●
応答の間		●		●
話題の妥当性			●	●
感情・テンション				●
キャラクター				●

旧 Q3 は Q1・Q2・Q4 の観点をすべて吸い込んでしまう → 評価者は他 3 軸の影響も Q3 に載せてしまい、軸として独立しない。

Q3 再設計の指針

包含を避け、Q3 を「対話としての話し方」に限定する

BEFORE (4/21)

Q3. 人と話している感じがしましたか？

感情表現・応答速度・キャラの一貫性

AFTER (4/28)

Q3. 対話としての話し方は自然でしたか？

韻律・感情表現・テンション・キャラクターの一貫性

根拠（4/21 議論より）

- 東芝システムの例: **完全にロボット音声でも、話し方が状況にマッチすれば人格として受容される**
- → Q3 の本質は「人間らしさ」ではなく **対話としての話し方** の自然さ
- プロソディ・パラ言語的な自然さは Q1（音質）とは別次元

Q3 の踏み込み度 — どこまで書くか

案A (保守) と 案B (一歩先) を併記

案 A — 保守的（推奨）

話し方は自然でしたか？

Gemini 的な一本調子との差を拾うレベル。評価が安定しやすい。

案 B — 一歩先

話し方はこちらと噛み合っていましたか？

整合性まで踏み込む。ただし評価者ごとに基準が揺れやすい懸念。

今回は 案 A（話し方が自然か） で進める

- 4/21 で「整合は一歩先に踏み出しすぎ」の懸念あり
- ブレイクダウン補助文で「噛み合い」の観点も拾う
- 100 名パイロット後、案 B に寄せるかは結果を見て判断

Q1. 音声の品質はどうでしたか？

Q1 音声の品質

音声の品質はどうでしたか？

BREAKDOWN（補助文・参考観点）

- ノイズは気になりませんでしたか？
- 発音は明瞭でしたか？
- 音量は安定していましたか？
- 声質は不自然に感じませんでしたか？

1 = 悪い ／ 5 = 良い

変更点

- 「音響品質」はノイズ寄りに聞こえる → **「音声の品質」** に改称
- 対話的なプロソディ（韻律の整合）は Q3 に分離（**音質単体**に絞る）

Q2. 対話のタイミングはどうでしたか？

Q2 対話のタイミング

対話のタイミングはどうでしたか？

BREAKDOWN（補助文・参考観点）

- 応答の間（ま）は自然でしたか？
- 相槌のタイミングは自然でしたか？
- ターン交代（話し始め・話し終わり）は自然でしたか？
- 沈黙や割り込みへの反応は自然でしたか？

1 = 悪い（早すぎ／遅すぎの両方）　5 = 良い

スケールの取り扱い

- 早すぎ・遅すぎを**どちらも「悪い」**として単調 1–5 に統一
- MOS 系と同じ方向性でそろえ、他軸との分析で混乱しないようにする

Q3. 対話としての話し方はどうでしたか？

Q3 対話としての話し方

対話としての話し方は自然でしたか？

BREAKDOWN（補助文・参考観点）

- 抑揚（イントネーション）は自然でしたか？
- 感情表現はこの場面にふさわしい度合いでしたか？
- 話す速さやテンションはこちらの喋り方に噛み合っていましたか？
- キャラクター（口調・人格）は会話を通して一貫していましたか？

1 = 悪い ／ 5 = 良い

狙い

- **音質ではない** プロソディ・パラ言語的な自然さ
- **タイミングではない** テンション・速度の**噛み合い**
- **応答内容ではない** キャラクターの一貫性

Q4. 応答内容はどうでしたか？

Q4 応答内容

応答内容は妥当でしたか？

BREAKDOWN（補助文・参考観点）

- 質問に対して的確な応答が返りましたか？
- 話題は噛み合っていましたか？
- 事実に反する発言（ハルシネーション）はありませんでしたか？
- 前の話の流れを踏まえた応答でしたか？

1 = 悪い ／ 5 = 良い

変更点

- 前回と同じ意味だが、**文型を「〜はどうでしたか」** に揃えた
- 文脈保持・ハルシネーションを補助文に明示

Q5 (Layer 2) と 付帯質問

Q5 **総合評価**

もう一度このモデルと話したいと思いましたか？

BREAKDOWN（参考観点）

- 会話の目的は達成できましたか？
- 情報として役に立ちましたか？
- 会話はスムーズに進みましたか？

1 = 思わない ／ 5 = また話したい

付帯質問（二値）

- **Q6**: 会話は成功しましたか？（成功 / 失敗）
- **Q7**: 音切れはありましたか？（あり / なし）

UI モック（更新版）

Q1 音声の品質はどうでしたか？
ノイズ・発音・音量・声質
1 2 3 4 5

Q2 対話のタイミングはどうでしたか？
間・相槌・ターン交代・沈黙
1 2 3 4 5

Q3 対話としての話し方は自然でしたか？
韻律・感情・テンション・キャラクター一貫性
1 2 3 4 5

Q4 応答内容は妥当でしたか？
的確さ・話題一致・ハルシネーション・文脈
1 2 3 4 5

— Layer 2 —

Q5 もう一度このモデルと話したいと思いましたか？
総合評価
1 2 3 4 5

— 付帯質問 —

Q6 会話は成功しましたか？
成功 失敗

Q7 音切れはありましたか？
あり なし

変更サマリー（前回 → 今回）

項目	4/21	4/28
Q1 タイトル	音響品質	**音声の品質**
Q1 文型	どう感じましたか	**〜はどうでしたか**
Q2 スケール注記	（なし）	**1 = 悪い（早/遅両方）〜 5 = 良い**
Q3 タイトル	人と話している感じ	**対話としての話し方**
Q3 焦点	人間らしさ全般（包含的）	**韻律・感情・テンション・キャラ一貫性** に限定
ブレイクダウン	hint 1 行のみ	**各 Q に 3–4 項目の補助文**
用語	キャラ	**キャラクター**

評価の安定性への配慮（4/21 議論より）

懸念

- 「趣味の話をしてください」レベルの指示だと、ユーザーがシステムに求めるものが人ごとにバラバラ
- → 特に Q3（話し方）の評価が不安定になりそう

対応案

- ワーカー向けに**話題と想定状況**を軽く固定する（例: 趣味の話、気楽な雑談）
- 参照用に**最低／最高例のクリップ**を事前に 1 度だけ提示（Step 5 の MUSHRA ライト運用）
- 100 名パイロットで軸間相関・被験者一致度を測定し、文言調整の判断材料に

残っているタスク

- ☐ **UI への反映** — `apps/web/src/components/wizard/steps/trial-step.tsx` の質問文を更新
- ☐ **ブレイクダウンの表示方法** — ツールチップ／常時展開／折りたたみ、どれにするか
- ☐ **参照クリップの選定** — 各軸の低品質／高品質サンプルを 1 本ずつ
- ☐ **100 名クラウドソーシング設計** — 話題指示、試料数、1 人あたり評価数
- ☐ **スキーマ更新** — `apps/web/prisma/schema.prisma` の評価カラム調整

SLT 2026 までのマイルストーン

- **2026-04-28**: 評価軸 v2 確定（本日）
- **2026-05-15**: パイロット 50 名収集完了
- **2026-05-31**: Bradley-Terry 分析・ドラフト v1
- **2026-06-17**: SLT 投稿

Q3 の先 — 個人／状況適応を学習で詰める

Q3 のブレイクダウンは全て「相手・状況への適応」の問題

抑揚・感情表現・テンション・キャラー貫性 → いずれも **相手／場面に合わせる** こと。

4/21 で出た「賑やか vs 淡々」「相手に応じた速度」「東芝システム: ロボット音声でも状況にマッチすれば人格として受容」はすべてこの軸に乗る。

評価側 — SLT 2026（本論文）

- FD-DMOS 5軸 + Layer 2 の確立
- Bradley-Terry による順位づけ
- 100 名クラウドソーシング

学習側 — IS 2027 / TASLP（次論文）

- Moshi fine-tune で相手／状況に適応
- prompt conditioning vs LoRA vs full FT
- 提案評価フレームで差分を検証

評価 → 学習 → 再評価 の閉ループを一連の研究成果として提示する連作戦略。

SLT Future Work + IS 2027 準備項目

SLT 論文の Future Work に書く骨子

- Q3 評価で低スコアのモデルは「話し方が相手と噛み合っていない」傾向があると示唆（パイロットで確認）
- 個人／状況適応を**学習目的関数に組み込む**方向を次論文で扱うと明示
- 具体的には Moshi fine-tune における条件付け手法の比較を予告

IS 2027 PoC のために先回り準備

項目	内容	時期
サーベイ	Persona dialog, style adaptation, FD-Bench 後続研究の空き地確認	2026-05
データ	ユーザー特性／状況ラベル付き対話コーパス（自作 or 既存流用）	2026-06〜07
手法	prompt conditioning / LoRA / full fine-tune の比較設計	2026-07〜09
評価	SLT で確立した FD-DMOS を**そのまま再利用**して差分検証	IS 2027 投稿時

→ 連作にすることで **評価フレーム自体の信頼性** も次論文で再確認できる

今日議論したいこと

1. Q3 の文言

- 案A「**対話としての話し方は自然でしたか**」で良いか
- 「噛み合い」まで踏み込む案B との比較

2. 各 Q のブレイクダウン補助文

- 4 項目ずつに過不足はないか
- UI 上の**表示方法**（常時展開 / ツールチップ / 折りたたみ）

3. Q2 のスケール注記

- 「早すぎ／遅すぎどちらも悪い」で単調 1–5 にする方針で OK か

4. 100 名パイロット時の話題設計

- 「趣味の話」で固定するか、もう少し具体化するか

5. 連作戦略（Q3 → 学習側）

- SLT の Future Work として個人／状況適応を書く方針で OK か
- IS 2027 向けサーベイを 5 月から着手して良いか

関連資料

プロジェクト内

- `slides/2026-04-21_eval-redesign.md` 前回スライド（5軸 + 二段構成の導出）
- `slides/2026-04-21_meeting-notes.md` **4/21 議論ログ**（本スライドの根拠）
- `slides/2026-04-21_submission-plan.md` SLT 2026 投稿プラン

実装対象

- `apps/web/src/components/wizard/steps/trial-step.tsx` 評価 UI（質問文）
- `apps/web/prisma/schema.prisma` 評価データスキーマ